

# Progetto di Modelli e metodi per l'inferenza statistica

Pietro Masini, Giulia Riccardi, Sofia Sannino, Alessandro Wiget 5 Giugno 2024 Obiettivo <sup>1</sup>

Vogliamo costruire un modello in grado di prevedere la probabilità di dropout di uno studente di ingegneria matematica al termine del primo semestre del primo anno.


Scelta di un modello di regressione logistico:

$$Y_i \sim Be(p_i)$$
  
 $\log\left(\frac{p_i}{1-p_i}\right) = Z\underline{b}$ 

dove Z è la matrice disegno e  $\underline{b}$  è il vettore dei parametri.


Il nostro dataset è del Politecnico di Milano e presenta covariate sia numeriche che categoriche.

Notiamo che ci sono persone che non hanno iniziato il corso e in più ci sono persone che sono iscritte da 3 anni e mezzo o più.




#### Correlazioni tra le covariate numeriche

5



### cfu vs. dropout



```
Call:
glm(formula = formula_num, family = binomial(link = logit), data = numerical_df)
Coefficients:
                         Estimate Std. Error z value Pr(>|z|)
(Intercept)
                        34.755964 66.394957 0.523
                                                       0.601
                        -0.015488 0.032665 -0.474 0.635
career start av
stud_admission_score
                        -0.002402
                                    0.010171 -0.236 0.813
stud_career_admission_age 0.098931
                                    0.148400 0.667
                                                       0.505
exa cfu pass
                        -0.168512
                                    0.014925 -11.290 < 2e-16 ***
exa grade average
                       -0.115155
                                   0.019016 -6.056 1.4e-09 ***
                                    0.238548 1.301
                                                       0.193
exa_avq_attempts
                        0.310379
highschool_grade
                                    0.009362 -2.044
                                                       0.041 *
                        -0.019135
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for binomial family taken to be 1)
   Null deviance: 2107.76 on 1879 degrees of freedom
Residual deviance: 815.99 on 1872 degrees of freedom
AIC: 831.99
Number of Fisher Scoring iterations: 6
```

exa\_cfu\_pass 0.1854219 exa\_grade\_average 0.8912281

Se uno studente acquisisce 10 cfu in più, il rischio di dropout diminuisce dell'80%.

Inoltre, il rischio di dropout diminuisce del 10% all'aumentare di un punto di media.

#### Selezione del modello tramite backward selection

```
Model:
dropout ~ exa_cfu_pass + exa_grade_average + highschool_grade
                 Df Deviance
                               AIC LRT Pr(>Chi)
                     818.49 826.49
<none>
exa_cfu_pass
                  1 967.13 973.13 148.641 < 2.2e-16 ***
exa_grade_average 1 862.97 868.97 44.479 2.571e-11 ***
highschool_grade 1 823.67 829.67 5.182
                                            0.02283 *
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Γ11 826.4862
Single term deletions
Model:
dropout ~ exa cfu pass + exa grade average
                 Df Deviance AIC LRT Pr(>Chi)
                     823.67 829.67
<none>
                  1 986.72 990.72 163.05 < 2.2e-16 ***
exa_cfu_pass
exa_grade_average 1 870.03 874.03 46.36 9.841e-12 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
[1] 826.4862
```

#### Modello finale con covariate numeriche

```
Call:
glm(formula = "dropout~1+exa_cfu_pass+exa_grade_average+highschool_grade",
   family = binomial. data = numerical df)
Coefficients:
               Estimate Std. Error z value Pr(>|z|)
              5.473043 0.838854 6.524 6.83e-11 ***
(Intercept)
exa cfu pass
             -0.167997 0.014626 -11.487 < 2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for binomial family taken to be 1)
   Null deviance: 2107.76 on 1879 degrees of freedom
Residual deviance: 818.49 on 1876 degrees of freedom
AIC: 826.49
Number of Fisher Scoring iterations: 6
```

#### Introduzione interazione tra le covariate numeriche

```
call:
alm(formula = dropout ~ exa_cfu_pass + exa_grade_average + highschool_grade +
   exa_cfu_pass:exa_grade_average, family = binomial, data = numerical_df)
Coefficients:
                            Estimate Std. Error z value Pr(>|z|)
                          4.674151 0.859873 5.436 5.45e-08 ***
(Intercept)
exa cfu pass
                         -0.037988 0.048964 -0.776
                                                      0.4378
exa_grade_average
                         -0.087164  0.016953  -5.141  2.73e-07 ***
highschool_grade
                          -0.015864 0.009292 -1.707 0.0878 .
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
(Dispersion parameter for binomial family taken to be 1)
   Null deviance: 2107.76 on 1879 degrees of freedom
Residual deviance: 810.78 on 1875 degrees of freedom
AIC: 820.78
Number of Fisher Scoring iterations: 6
```

# Introduzione variabili categoriche

```
Coefficients:
                                          Estimate Std. Error z value Pr(>|z|)
                                                                4.666 3.08e-06
(Intercept)
                                          4.811048
                                                     1.031176
exa_cfu_pass
                                         -0.166832
                                                     0.014937 -11.169 < 2e-16
***
                                         -0.111726
                                                     0.017680 -6.320 2.62e-10
exa_grade_average
stud_genderM
                                          0.302170
                                                     0.202790
                                                                1.490
                                                                        0.1362
previousStudiesOthers
                                          1.334128
                                                     0.657691
                                                                2.029
                                                                        0.0425 *
previousStudiesScientifica
                                          0.355375
                                                     0.371562
                                                                0.956
                                                                        0.3389
previousStudiesTecnica
                                          1.184662
                                                     0.565604
                                                                2.095
                                                                        0.0362 *
originsForeigner
                                         -0.396477
                                                     1.195581
                                                               -0.332
                                                                        0.7402
originsMilanese
                                         -0.224974
                                                     0.219894
                                                               -1.023
                                                                        0.3063
oriainsOffsite
                                         -0.779675
                                                     0.640482
                                                               -1.217
                                                                        0.2235
income_bracket_normalized_on4fascia bassa 0.083811
                                                    0.269375 0.311
                                                                        0.7557
income_bracket_normalized_on4fascia media
                                          0.176529
                                                     0.227462
                                                                0.776
                                                                        0.4377
income_bracket_normalized_on4LS
                                          -0.531922
                                                     0.355726
                                                               -1.495
                                                                        0.1348
highschool_grade
                                          -0.017799
                                                               -1.795
                                                                        0.0727 .
                                                     0.009916
               0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Signif. codes:
(Dispersion parameter for binomial family taken to be 1)
    Null deviance: 2107.76 on 1879 degrees of freedom
```

on 1866


AIC: 829.76

Residual deviance: 801.76

Tramite una backward selection, sono state selezionate le covariate significative.

E' emerso che nessuna covariata categorica è significativa. Il modello ottimale rimane quello con le sole numeriche.

# Classificazione, curva ROC, confusion matrix



Soglia ottimale: 0.2181341

### Classificazione, curva ROC, confusion matrix

```
Reference
Prediction 0 1
0 266 11
1 24 75
```

Accuracy: 0.9069

95% CI : (0.8729, 0.9343)

No Information Rate : 0.7713 P-Value [Acc > NIR] : 5.045e-12

Kappa : 0.7495

Mcnemar's Test P-Value : 0.04252

Sensitivity: 0.9172 Specificity: 0.8721 Pos Pred Value: 0.9603 Neg Pred Value: 0.7576 Prevalence: 0.7713 Detection Rate: 0.7074

Detection Prevalence: 0.7367 Balanced Accuracy: 0.8947 Usando il valore soglia arrontondato e il modello ottimale costruito, la probabilità predetta sugli studenti attivi è circa del 37%.

Fonti